

## CODICI DI HUFFMAN

- CONSENTONO FATTORI DI COMPRESSIONE TRA IL 20% E IL 90%
- PROBLEMA: TROVARE UNA CODIFICA DI UN FILE DI CARATTERI IN MODO DA MINIMIZZARNE LA DIMENSIONE

ESEMPIO: FILE DI 100 CARATTERI

CAR.	FREQ.	COD 1 (8 BIT)	COD 2 (3 bit)	COD 3	
a	45 x 1	00000000	000	0	45
b	13 x 3	00000001	001	101	39
c	12 x 3	00000010	010	100	36
d	16 x 3	00000011	011	111	48
e	9 x 4	00000100	100	1101	36
f	5 x 4	00000101	101	1100	20
100		800 bit	300 bit	224 bit	

ES. abac

COD 2

000001000010


COD 3

01010100

LUNGHEZZA FISSA

LUNGH. VARIABILE

25% IN MEMO



$$86 \times 3 + 14 \times 2 = 258 + 28$$

## ALBERI DI DECODIFICA

CAR.	FREQ.	COD2 (3 bit)	COD3
a	45	000	0
b	13	001	101
c	12	010	100
d	16	011	111
e	9	100	1101
f	5	101	1100

ES.

a b a c

COD2

000 001 000 010


a b a c

COD3


0 1010100

a b a c

COD2



COD3




PIENO/FULL

- CODICI PREFISSI: SONO CODICI IN CUI NESSUNA CODIFICA E' PREFISSO DI UN'ALTRA CODIFICA

ESEMPIO DI CODICE NON PREFISSO NON AMBIGUO

a 0  
b 01  
c 11

011111111111  
b c c c a c



ESEMPIO DI CODICE NON PREFISSO AMBIGUO

a 0  
b 1  
c 01



?

$$f: C \rightarrow \mathbb{N}$$

## ALBERI DI DECODIFICA

CAR.	FREQ.	COD2 (3 bit)	COD3
a	45 x 1	000	0
b	13 x 3	001	101
c	12 x 3	010	100
d	16 x 3	011	111
e	9 x 4	100	1101
f	5 x 4	101	1100

COMPLESSITA' DELLA CODIFICA:

$$B(\text{cod}) = \sum_{c \in C} f(c) | \text{cod}(c) |$$



$$= \sum_{c \in C} f(c) d_{T_{\text{cod}}}(c) \stackrel{\text{def}}{=} B(T_{\text{cod}})$$

$T_{\text{cod}}$ : ALBERO DI DECODIFICA

$C$ : ALFABETO

$$f: C \rightarrow \mathbb{N}$$

$d_{T_{\text{cod}}}$ : PROFONDITA' IN  $T_{\text{cod}}$



PROBLEMA: TRA TUTTI GLI ALBERI DI DECODIFICA  
RELATIVI AD UN SISTEMA  $(C, f)$  (DOVE  
 $f: C \rightarrow \mathbb{N}$ ) DETERMINARE QUELLO DI  
COSTO MINIMO, CIOE' L'ALBERO  
BINARIO DI DECODIFICA  $T$  TALE CHE

$$B(T) = \sum_{c \in C} f(c) d_T(c)$$

SIA MINIMO


OSSERVAZIONE: POSSIAMO LIMITARE LA NOSTRA RICERCA  
AGLI ALBERI BINARI PIENI, QUELLI CIOE' PRIVI  
DI NODI INTERNI CON UN SOLO FIGLIO.

OSSERVAZIONE: IL NUMERO DI NODI INTERNI  
IN UN ALBERO BINARIO PIENO CON  
 $n$  FOGLIE E'  $n-1$ .

$$n = 1 \quad I = n - 1 = 1 - 1$$

---

$$n > 1$$



$$n_1 + n_2 = n$$


$$(n_1 - 1) + (n_2 - 1) + 1$$

---

$$= \underbrace{n_1 - 1} + \underbrace{n_2 - 1} + 1$$


---

$$= n - 1$$



- PER COSTRUIRE UN ALBERO BINARIO PIENO CON  $m$  NODI SI POSSONO EFFETTUARE  $(m-1)$  OPERAZIONI DI MERGING





$$C_1 \cup C_2 = C$$

$$c \in C_1 \quad d_{T_1}(c) + 1 = d_T(c)$$

$$c \in C_2 \quad d_{T_2}(c) + 1 = d_T(c)$$

$$B(T) = \sum_{c \in C} f(c) \cdot d_T(c)$$


$$= \sum_{c \in C_1} f(c) \cdot d_T(c) + \sum_{c \in C_2} f(c) \cdot d_T(c)$$

$$= \sum_{c \in C_1} f(c) (d_{T_1}(c) + 1) + \sum_{c \in C_2} f(c) (d_{T_2}(c) + 1)$$

$$= \sum_{c \in C_1} f(c) d_{T_1}(c) + \sum_{c \in C_1} f(c)$$

$$+ \sum_{c \in C_2} f(c) d_{T_2}(c) + \sum_{c \in C_2} f(c)$$

$$= B(T_1) + B(T_2) + \sum_{c \in C} f(c)$$



$$C_1 \cup C_2 = C$$

$$c \in C_1 \quad d_{T_1}(c) + 1 = d_T(c)$$

$$c \in C_2 \quad d_{T_2}(c) + 1 = d_T(c)$$

$$B(T) = B(T_1) + B(T_2) + \sum_{c \in C} f(c)$$

$$\Delta B = B(T) - (B(T_1) + B(T_2))$$

$$= \sum_{c \in C} f(c) \quad \leftarrow \text{COSTO DELL'}$$

OPERAZIONE DI  
MERGING DI  
 $T_1$  E  $T_2$




$$\begin{array}{r}
 14 \\
 30 \\
 25 \\
 55 \\
 \hline
 100 \\
 224
 \end{array}$$

PER INDUZIONE SULL'ALTEZZA DI  $T$ , SI DIMOSTRA CHE:

$B(T) =$  SOMMA DEI COSTI DI TUTTE LE OPERAZIONI  
DI MERGING

CASO BASE:  $\text{height}(T) = 1$        $B(T) = \text{merging}(\text{root}(T))$

PASSO INDUTTIVO:




$$B(T) = B(T_1) + B(T_2) + \sum_{c \in C} f(c)$$

$$= \sum_{v \in \text{int}(T_1)} \text{merging}(v) + \sum_{v \in \text{int}(T_2)} \text{merging}(v) + \text{merging}(\text{root}(T))$$

$$= \sum_{v \in \text{int}(T)} \text{merging}(v)$$

ESEMPIO:

1 0 0 1 0 1



14 +  
30 +  
25 +  
55 +  
100  
-----  
224

- UNA POSSIBILE STRATEGIA "GREEDY" PER COSTRUIRE UN ALBERO DI COSTO MINIMO CONSISTE NELL'EFFETTUARE LE OPERAZIONI DI MERGING DI COSTO MINIMO

HUFFMAN( $C, f$ )

$n := |C|$

$Q := \text{make\_queue}(C, f)$

for  $i := 1$  to  $n-1$  do

- SI ALLOCA UN NUOVO NODO INTERNO  $z$

$\text{left}[z] := x := \text{EXTRACT\_MIN}(Q)$

$\text{right}[z] := y := \text{EXTRACT\_MIN}(Q)$

$f[z] := f[x] + f[y]$

$\text{INSERT}(Q, z, f)$

return  $\text{EXTRACT\_MIN}(Q)$

COMPLESSITA'

$(2n-1)$  EXTRACTMIN  $O(n \log n)$


$(n-1)$  INSERT  $O(n \log n)$

BUILDHEAP  $O(n)$

$O(n \log n)$

# ESEMPIO


a:45




d:16





a:45





(3) d:16



a:45






$a = 0$   
 $b = 100$   
 $c = 101$   
 $d = 110$   
 $e = 1110$   
 $f = 1111$

LOWER-BOUND SULLA COMPLESSITA':  $\Omega(n \lg n)$

$$\begin{cases} F(0) = 1 \\ F(1) = 1 \\ F(n) = F(n-1) + F(n-2) \end{cases}$$



a 00000  
b 00001  
c 0001  
d 001  
e 01  
f 1



## CORRETTEZZA DELL'ALGORITMO DI HUFFMAN

### LEMMA

SIA  $C$  UN ALFABETO E  $f: C \rightarrow \mathbb{N}$  UNA FUNZIONE FREQUENZA.

SIANO  $x$  ED  $y$  I DUE CARATTERI IN  $C$  DI FREQUENZA MINIMA.



ALLORA ESISTE UN CODICE OTTIMO PREFISSO PER  $C$  IN CUI LE CODIFICHE DI  $x$  ED  $y$  DIFFERISCONO SOLO PER L' ULTIMO BIT.

DIM. SIANO  $a$  E  $b$  DUE CARATTERI RESIDENTI SU FOGLIE  
 SORELLE DI PROFONDITA' MASSIMA IN UN ALBERO OTTIMO  $T$ .

SUPPONIAMO CHE  $f(a) \leq f(b)$  E  $f(x) \leq f(y)$ .

ALLORA:  $f(x) \leq f(a)$  E  $f(y) \leq f(b)$ ,

SIA  $T'$  L'ALBERO OTTENUTO DA  $T$  SCAMBIANDO  
 I CARATTERI  $a$  ED  $x$ ,



SI HA:

$$\begin{aligned} B(T) - B(T') &= \sum_{c \in C} f(c) d_T(c) - \sum_{c \in C} f(c) d_{T'}(c) \\ &= f(a) d_T(a) + f(x) d_T(x) - f(a) d_{T'}(a) - f(x) d_{T'}(x) \\ &= f(a) d_T(a) + f(x) d_T(x) - f(a) d_T(x) - f(x) d_T(a) \\ &= f(a) (d_T(a) - d_T(x)) - f(x) (d_T(a) - d_T(x)) \\ &= (f(a) - f(x)) (d_T(a) - d_T(x)) \geq 0 \end{aligned}$$

POICHE' :

- $c \in C \setminus \{a, x\} \longrightarrow d_T(c) = d_{T'}(c)$
- $d_{T'}(a) = d_T(x)$
- $d_{T'}(x) = d_T(a)$

- SIA  $T''$  L'ALBERO OTTENUTO DA  $T'$  SCAMBIANDO  
I CARATTERI  $b$  ED  $y$ ,

- ANALOGAMENTE A QUANTO VISTO PRIMA, SI HA:

$$B(T') - B(T'') \geq 0$$

- PERTANTO:  $B(T) - B(T'') \geq 0$ , DA CUI

$$B(T) \geq B(T'')$$

- POICHE'  $T$  E' OTTIMO,  $B(T'') \geq B(T)$ , E QUINDI

$B(T'')$  E' ANCH'ESSO OTTIMO

- INOLTRE IN  $T''$  I CARATTERI  $x$  E  $y$  RISIEDONO SU  
FOGLIE SORELLE E QUINDI I LORO CODICI DIFFERISCONO  
SOLO PER L'ULTIMO BIT. ■

### LEMMA

- SIA  $C$  UN ALFABETO E  $f: C \rightarrow \mathbb{N}$  UNA FUNZIONE FREQUENZA.
  - SIANO  $x$  ED  $y$  I DUE CARATTERI IN  $C$  DI FREQUENZA MINIMA.
  - SIA  $C' = (C \setminus \{x, y\}) \cup \{z\}$ , CON  $z \notin C$ .
  - SIA  $f': C' \rightarrow \mathbb{N}$  TALE CHE: 
$$f'(c) = \begin{cases} f(c) & \text{SE } c \neq z \\ f(x) + f(y) & \text{SE } c = z \end{cases}$$
  - SIA  $T'$  UN ALBERO OTTIMO PER  $(C', f')$ .
  - SIA  $T$  L'ALBERO OTTENUTO DA  $T'$  SOSTITUENDO LA FOGLIA  $z$  CON UN NODO INTERNO AVENTE COME FIGLI DUE FOGLIE ETICHETTATE CON  $x$  ED  $y$ , RISPETTIVAMENTE.
- ALLORA  $T$  E' OTTIMO PER  $(C, f)$ .

SIN QUI 30/11/2021

DIM. SI HA:

$$B(T) = \sum_{c \in C} f(c) d_T(c) = \sum_{c \in C \setminus \{x, y\}} f(c) d_T(c) + f(x) d_T(x) + f(y) d_T(y)$$

$$= \sum_{c \in C \setminus \{x, y\}} f'(c) d_{T'}(c) + f(x)(d_{T'}(z)+1) + f(y)(d_{T'}(z)+1)$$

$$= \sum_{c \in C \setminus \{x, y\}} f'(c) d_{T'}(c) + f'(z) d_{T'}(z) + f(x) + f(y)$$

$$= \sum_{c \in C'} f'(c) d_{T'}(c) + f(x) + f(y)$$

$$= B(T') + f(x) + f(y)$$

DA CUI:  $B(T') = B(T) - f(x) - f(y)$

- SE  $T$  NON FOSSE OTTIMO PER  $(C, f)$ , ESISTEREBBE UN ALBERO  $T''$  OTTIMO PER  $(C, f)$  TALE CHE:  
 $B(T'') < B(T)$ .
- GRAZIE AL LEMMA PRECEDENTE, POSSIAMO SUPPORRE CHE  $x$  E  $y$  SI TROVINO SU FOGLIE SORELLE IN  $T''$ .
- SIA  $T'''$  OTTENUTO DA  $T''$ , SOSTITUENDO IL PADRE DI  $x$  E  $y$  CON UNA FOGLIA  $z$  CON FREQUENZA  $f(x) + f(y)$ .
- ALLORA:
 
$$\begin{aligned}
 B(T''') &= B(T'') - f(x) - f(y) \\
 &< B(T) - f(x) - f(y) \\
 &= B(T')
 \end{aligned}$$

CONTRADDICENDO L'OTTIMALITA' DI  $T'$  PER  $(C', f')$ .

- PERTANTO  $T$  E' OTTIMO PER  $(C, f)$ . ■